

Représenter le LiDAR 3D par une hiérarchie Hypergraph-Percol



Encodage géométrique et premiers tests


Louis HAUSEUX Zoltán KATÓ Josiane ZERUBIA

Inria / Szegedi Tudományegyetem

16 septembre 2026



Vers un modèle de fondation pour la 3D ?



[Brown 20] T. Brown *et al.*, *Language Models are Few-Shot Learners*, NeurIPS, 2020.


[SAM 23] A. Kirillov *et al.*, *Segment Anything*, ICCV, 2023.

[Sonata 25] X. Wu *et al.*, *Sonata : Self-Supervised Learning of Reliable Point Representations*, CVPR, 2025.

[Utonia 26] Y. Zhang *et al.*, *Utonia : Toward One Encoder for All Point Clouds*, ICML, 2026.

[Vernata 26] O. Lemke, A. Liniger, A. Gawel, M. Hutter, *Vernata : Self-Supervised Learning of LiDAR Point Representations*, arXiv:2608.06919, 2026 (annoncé IROS 2026).


Hypothèse : le nuage est un *artefact du capteur*



- ▶ La **densité** décroît avec la portée ; s'y ajoutent les nappes de balayage et les **occultations**
- ▶ Un modèle point par point apprend donc *en même temps* la géométrie, le capteur, la densité, l'occultation **et** la sémantique
- ▶ Hypothèse : c'est *une* raison centrale de la difficulté



Une hiérarchie de polyèdres [Thèse 26]



À chaque nœud v , une géométrie

$$P_v = \bigcup_{\sigma \in \mathcal{F}_v} \sigma.$$

Points, arêtes ou faces.

Conserver les **parents, enfants et niveaux r** .

Les appartenances des points peuvent se recouvrir.

[Thèse 26] L. Hauseux, *Utilisation de graphes pour la classification et l'extraction de structures. Généralisation à des interactions d'ordre supérieur*, thèse de doctorat, Université Côte d'Azur, 2026, parties I–II.

La hiérarchie est définie dans la thèse (parties I–II) ; la réalisation géométrique P_v reste à choisir.

Questions

1. Qu'est-ce qu'un polyèdre ? Comment le représenter vectoriellement ?
2. La question des attributs : couleur, autres caractéristiques physiques, *etc.*
3. Comment mesurer la pertinence de cette représentation ?
Polyèdres **et** hiérarchie.
4. Première intégration légère avec une I.A. : LoRA ? [LoRA 22]
5. L'architecture complète.

[LoRA 22] E. J. Hu *et al.*, *LoRA : Low-Rank Adaptation of Large Language Models*, ICLR, 2022.



La fonction support [Schneider 13]


Pour une direction unitaire u :

$$h_P(u) = \max_{x \in P} \langle u, x \rangle .$$

Hauteur du premier contact avec un plan de normale u .

Si P est **convexe**, tous ses plans d'appui déterminent P .

$$h_P = h_{\text{conv}(P)}.$$




[Schneider 13] R. Schneider, *Convex Bodies : The Brunn–Minkowski Theory*, 2^e éd., Cambridge University Press, 2013.

P compact non vide ; dessin en coupe 2D.

Support quadratique et distance

$$C_P = \text{conv} \{ (x, \|x\|^2) : x \in P \} \subset \mathbb{R}^4.$$

$$\underbrace{h_{C_P}(2b, -1)}_{H_P(b)} = \|b\|^2 - d_P(b)^2.$$



b est une **sonde** dans l'espace.

$$d_P(b) = \min_{x \in P} \|b - x\|.$$

Distance aux arêtes et faces entières.

H_P est convexe, même si P ne l'est pas.

$$H_P(b) = \max_{x \in P} (2 \langle b, x \rangle - \|x\|^2). \text{ Relèvement de toute la réalisation } P, \text{ pas seulement des sommets.}$$



Les propriétés utiles, sans convexité

Géométrie $P = \{b : d_P(b) = 0\}$

Stabilité $\|d_P - d_Q\|_\infty = d_H(P, Q)$


Union $d_{P \cup Q} = \min(d_P, d_Q)$

Pour des compacts non vides : arêtes, surfaces ouvertes ou unions de morceaux.

d_H : distance de Hausdorff. Les fonctions sont comparées aux mêmes positions, dans un repère commun.



Un vecteur par polyèdre



$8^3 = 512$ sondes

c_v : centre de la boîte englobante.

s_v : moitié du plus grand côté.

$$\hat{P}_v = (P_v - c_v)/s_v \subset [-1, 1]^3.$$

Aucune rotation locale.

$$D_v[j] = \frac{d(c_v + s_v b_j, P_v)}{s_v}, \quad j = 1, \dots, 512.$$

Conserver aussi : centre, taille, niveau HGP, attributs LiDAR. **[BPS 19]**

[BPS 19] S. Prokudin, C. Lassner, J. Romero, *Efficient Learning on Point Clouds with Basis Point Sets*, ICCV, 2019, p. 4332–4341.

Adaptation : distances à la réalisation P_v , non aux seuls retours. Code fini approché ; cas ponctuels traités séparément.



Sphère en 4D ou cube en 3D ?

Dans les deux cas : $\hat{P} = (P - c)/s$, puis $C_{\hat{P}}$.

Directions du support relevé

$$u_j \in S^3 \subset \mathbb{R}^4, \quad h_{C_{\hat{P}}}(u_j).$$

Échantillonner des normales d'appui en dimension 4.

Sondes de distance dans le cube

$$b_j \in [-1, 1]^3, \quad d_{\hat{P}}(b_j).$$

Échantillonner des positions dans le volume normalisé.

$$u(b) = \frac{(2b, -1)}{\sqrt{1 + 4 \|b\|^2}}, \quad h_{C_{\hat{P}}}(u(b)) = \frac{\|b\|^2 - d_{\hat{P}}(b)^2}{\sqrt{1 + 4 \|b\|^2}}.$$

La grille correspond à des directions précises avec $u_4 < 0$,
pas à un échantillonnage uniforme de toute S^3 .

Même information aux sondes correspondantes, à un facteur connu près. Aucun convexe 4D à construire pour calculer les distances.



La hiérarchie retrouve-t-elle les instances ?

S_v : points couverts ; G : instance annotée [SemanticKITTI 19].

$$\max_v \text{IoU}(S_v, G) = \max_v \frac{|S_v \cap G|}{|S_v \cup G|}.$$



Comparer HGP, $K = 1$ et grilles imbriquées, à budget de régions comparable.

Rapporter le rappel des instances selon le seuil d'IoU.

[SemanticKITTI 19] J. Behley et al., *SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences*, ICCV, 2019.

Oracle sur les masques de points, non segmentation prédite. Exemple dessiné, non résultat expérimental.

Mesurer un apport avec un petit modèle

Même petit réseau supervisé, mêmes données et budgets.

	Régions	Distances aux sondes
A	Voisinages spatiaux	Aux points
B	Régions HGP	Aux points
C	Mêmes régions HGP	Aux arêtes ou faces

B contre A : choix des régions.

C contre B : réalisation géométrique.

Mesurer la mIoU par classe et par portée, ainsi que le coût.

Liens hiérarchiques : mêmes codes, avec / sans échanges parent–enfant.

Protocole proposé ; réseau et budgets appariés. Contrôle de robustesse : 50 % puis 25 % des retours, HGP et codes recalculés.



Bibliographie (1/2)

- ▶ **[Brown 20]** T. Brown *et al.*, *Language Models are Few-Shot Learners*, NeurIPS, 2020.
- ▶ **[SAM 23]** A. Kirillov *et al.*, *Segment Anything*, ICCV, 2023.
- ▶ **[Sonata 25]** X. Wu *et al.*, *Sonata : Self-Supervised Learning of Reliable Point Representations*, CVPR, 2025.
- ▶ **[Utonia 26]** Y. Zhang *et al.*, *Utonia : Toward One Encoder for All Point Clouds*, ICML, 2026.
- ▶ **[Vernata 26]** O. Lemke, A. Liniger, A. Gawel, M. Hutter, *Vernata : Self-Supervised Learning of LiDAR Point Representations*, arXiv:2608.06919, 2026 (annoncé IROS 2026).



Bibliographie (2/2)

- ▶ **[Thèse 26]** L. Hauseux, *Utilisation de graphes pour la classification et l'extraction de structures. Généralisation à des interactions d'ordre supérieur*, thèse de doctorat, Université Côte d'Azur, 2026, parties I–II.
- ▶ **[LoRA 22]** E. J. Hu *et al.*, *LoRA : Low-Rank Adaptation of Large Language Models*, ICLR, 2022.
- ▶ **[Schneider 13]** R. Schneider, *Convex Bodies : The Brunn–Minkowski Theory*, 2^e éd., Cambridge University Press, 2013.
- ▶ **[BPS 19]** S. Prokudin, C. Lassner, J. Romero, *Efficient Learning on Point Clouds with Basis Point Sets*, ICCV, 2019, p. 4332–4341.
- ▶ **[SemanticKITTI 19]** J. Behley *et al.*, *SemanticKITTI : A Dataset for Semantic Scene Understanding of LiDAR Sequences*, ICCV, 2019.